

LAPORAN TUBES UTS

KEAMANAN INFORMASI LANJUT

Implementasi Federated Learning Berbasis Flower Framework untuk Deteksi Anomali Jaringan pada Dataset CIC Menggunakan Docker



Disusun Oleh :
Nurul Qadriyyah | 201012530003

Tahun Ajaran 2025/2026

Daftar Isi

1. Ringkasan.....	3
2. Latar Belakang dan Tujuan	3
3. Framework dan Komponen Sistem.....	3
4. Dataset, Label, dan Fitur	4
5. Arsitektur Model AI	5
6. Alur Kerja Federated Learning	5
7. Matriks Evaluasi dan Hasil Eksperimen.....	6
7.1 Penjelasan Matriks/Metrik Evaluasi.....	8
8. Analisis Hasil	8
8.1 Interpretasi Non-IID	9
9. Deteksi CSV Baru Tanpa Label	9
10. Keterbatasan dan Rekomendasi Pengembangan	9
11. Kesimpulan.....	10
Lampiran A. Daftar Fitur Dataset	11
Lampiran B. Command Operasional Docker	12
Lampiran C. Ringkasan Log Eksperimen yang Digunakan	13

1. Ringkasan

Laporan ini menjelaskan implementasi sistem deteksi anomali jaringan berbasis Federated Learning menggunakan framework Flower, TensorFlow/Keras, dan Docker Compose. Sistem dibangun dengan satu server federated learning sebagai aggregator dan tiga node/client sebagai pelatih lokal. Setiap node melakukan training pada dataset lokal masing-masing tanpa mengirim data mentah ke server. Server hanya menerima parameter model dan metrik evaluasi, kemudian melakukan agregasi menggunakan strategi FedAvg.

Berdasarkan hasil eksperimen, proses federated learning selesai dalam 3 round selama 114,30 detik. Loss global turun dari 0,8234 pada round pertama menjadi 0,3982 pada round ketiga. Accuracy global meningkat dari 79,97% menjadi 90,05%. Hasil ini menunjukkan bahwa proses federated learning berhasil melakukan konvergensi awal dan memperbaiki performa model global dari round ke round.

Namun, akurasi antar-node tidak merata. Node-1 memperoleh accuracy 71,85%, sedangkan Node-2 dan Node-3 masing-masing mencapai 98,50% dan 99,80%. Ketimpangan ini penting untuk dicatat karena menunjukkan karakteristik non-IID pada data federated learning. Node dengan distribusi data yang lebih kompleks atau lebih banyak pola serangan cenderung menghasilkan evaluasi yang lebih rendah dibanding node yang dominan berisi trafik normal.

2. Latar Belakang dan Tujuan

Intrusion Detection System (IDS) bertujuan mengidentifikasi aktivitas jaringan yang menyimpang dari pola normal, seperti DDoS dan PortScan. Pada pendekatan machine learning konvensional, seluruh data biasanya dikumpulkan pada satu server pusat untuk proses training. Pendekatan tersebut tidak selalu ideal karena data jaringan dapat tersebar di banyak lokasi dan memiliki pertimbangan privasi, bandwidth, maupun keamanan.

Federated Learning menawarkan pendekatan terdistribusi: model dilatih secara lokal pada masing-masing node, kemudian hanya parameter model yang dikirim ke server untuk digabungkan. Dalam konteks IDS, pendekatan ini relevan karena setiap lokasi jaringan dapat memiliki pola trafik lokal yang berbeda, sementara sistem tetap dapat membangun model global tanpa memusatkan data mentah.

Tujuan	Penjelasan
Membangun pipeline federated learning	Menjalankan server Flower dan tiga client pada Docker Compose.
Melatih model klasifikasi IDS	Membedakan kelas BENIGN, DDoS, dan PortScan menggunakan neural network.
Mengukur performa global	Menganalisis loss dan accuracy global pada setiap round.
Mengevaluasi performa lokal	Membandingkan loss dan accuracy Node-1, Node-2, dan Node-3.
Menyiapkan deteksi CSV baru	Model hasil training dapat dipakai untuk prediksi CSV uji tanpa kolom Label.


3. Framework dan Komponen Sistem

Sistem menggunakan kombinasi beberapa komponen. Docker Compose bertugas menjalankan seluruh service secara terisolasi tetapi berada pada network Docker yang sama. Flower bertugas mengatur komunikasi federated learning antara server dan client. TensorFlow/Keras digunakan untuk mendefinisikan model neural network. Pandas dan NumPy digunakan untuk membaca CSV, membersihkan fitur, melakukan normalisasi, dan mempersiapkan label.

Komponen	Peran Teknis	Output/Interaksi
Docker Compose	Mengorkestrasi service server, node1, node2, dan node3 dalam satu network.	Menjalankan container Server-FL, Node-1, Node-2, dan Node-3.
Flower Server	Aggregator federated learning dengan strategi FedAvg.	Menerima bobot model dan metrik dari semua client, lalu mengirim model global

		baru.
Flower Client	Node lokal yang melakukan training dan evaluasi terhadap dataset masing-masing.	Menghasilkan bobot model lokal, loss, accuracy, dan file model .h5.
TensorFlow/Keras	Membangun dan melatih neural network klasifikasi.	Model Dense dengan output softmax tiga kelas.
Pandas/NumPy	Membaca CSV, memisahkan fitur dan label, normalisasi data numerik.	X terstandarisasi dan y one-hot encoded.
CSV Dataset CIC	Sumber data trafik jaringan.	Fitur numerik trafik dan kolom Label.

Gambar berikut memperlihatkan arsitektur kerja sistem.



Gambar 1. Arsitektur Federated Learning IDS dengan Server-FL dan tiga node client.

4. Dataset, Label, dan Fitur

Dataset yang digunakan berbentuk CSV dan dibagi ke dalam tiga node. Setiap node memiliki 2.000 record. Pada tahap training supervised, kolom Label wajib tersedia karena label digunakan untuk membentuk target klasifikasi. Pada tahap deployment atau deteksi CSV baru, kolom Label tidak wajib ada karena model akan memprediksi kelas secara otomatis.

Node	File Dataset	Jumlah Record	Jumlah Fitur	Distribusi Label
Node-1	dataset_node1_ddos.csv	2000	77	DDoS: 1172; Benign: 828
Node-2	dataset_node2_portscan.csv	2000	77	Benign: 1970; PortScan: 30
Node-3	dataset_node3_benign.csv	2000	77	Benign: 2000

Terdapat 77 fitur input numerik dan 1 kolom Label. Fitur-fitur tersebut menggambarkan karakteristik aliran trafik jaringan, seperti durasi flow, jumlah paket, panjang paket, interval waktu antar-paket, flag TCP, rasio downstream/upstream, ukuran segment, subflow, window size, active time, dan idle time.

Kelompok Fitur	Contoh Fitur	Fungsi Analitis
Identitas flow	Protocol	Menggambarkan protokol trafik yang digunakan.
Volume paket	Total Fwd Packets, Total Backward Packets	Jumlah paket arah forward dan backward.

Panjang paket	Fwd/Bwd Packet Length Max, Min, Mean, Std	Statistik ukuran paket pada dua arah komunikasi.
Kecepatan trafik	Flow Bytes/s, Flow Packets/s, Fwd Packets/s, Bwd Packets/s	Laju byte dan paket per detik.
Inter-arrival time	Flow IAT, Fwd IAT, Bwd IAT	Interval waktu antar-paket; penting untuk pola burst DDoS.
TCP flags	FIN, SYN, RST, PSH, ACK, URG, CWE, ECE	Indikator perilaku koneksi TCP.
Rasio dan segment	Down/Up Ratio, Avg Packet Size, Avg Segment Size	Perbandingan arah trafik dan ukuran rata-rata paket/segment.
Subflow	Subflow Fwd/Bwd Packets/Bytes	Ringkasan per-subflow.
Window dan aktivitas	Init Fwd/Bwd Win Bytes, Active, Idle	Karakteristik window awal dan pola aktif/idle koneksi.

5. Arsitektur Model AI

Model yang digunakan adalah neural network sederhana berbasis fully connected layer. Input model adalah seluruh fitur numerik setelah normalisasi. Output model terdiri dari tiga neuron dengan aktivasi softmax untuk memprediksi kelas BENIGN, DDoS, atau PortScan.

Lapisan	Konfigurasi	Fungsi
Input	Jumlah neuron = jumlah fitur input, yaitu 77 fitur.	Menerima vektor fitur trafik jaringan.
Dense 1	64 neuron, aktivasi ReLU.	Mempelajari pola non-linear awal dari fitur trafik.
Dense 2	32 neuron, aktivasi ReLU.	Memadatkan representasi fitur dan meningkatkan kapasitas klasifikasi.
Output	3 neuron, aktivasi Softmax.	Menghasilkan probabilitas kelas BENIGN, DDoS, dan PortScan.
Loss	Categorical crossentropy.	Mengukur kesalahan klasifikasi multi-kelas.
Optimizer	Adam.	Mengoptimalkan bobot model lokal pada setiap client.

Normalisasi fitur dilakukan dengan standardisasi:

$$X_{\text{norm}} = (X - \text{mean}) / (\text{std} + 1e-7)$$

Penambahan nilai 1e-7 pada penyebut digunakan untuk menghindari pembagian dengan nol jika terdapat fitur dengan standar deviasi sangat kecil atau nol.

6. Alur Kerja Federated Learning

Alur kerja sistem terdiri dari proses persiapan data, training lokal, pengiriman bobot ke server, agregasi model global, evaluasi, dan penyimpanan model hasil training. Karena sistem menggunakan FedAvg, server menggabungkan bobot model client berdasarkan jumlah data yang dimiliki tiap client.

Tahap	Aktor	Proses	Output
1. Inisialisasi	Server-FL	Server Flower berjalan pada 0.0.0.0:8081 dan menunggu tiga client.	Server siap menerima koneksi.
2. Load dataset	Node-1/2/3	Client membaca CSV sesuai node_id dan memisahkan X dari Label.	Matriks fitur X dan target y.
3. Preprocessing	Node-1/2/3	Fitur dikonversi menjadi numerik, distandardisasi, dan label dirapikan.	Data siap training.
4. Training lokal	Node-1/2/3	Masing-masing client melatih model lokal selama 5 epoch per round.	Bobot model lokal.
5. Agregasi	Server-FL	Server menerima bobot dari 3 client dan melakukan FedAvg.	Model global baru.
6. Evaluasi	Node-1/2/3	Client mengevaluasi model global pada data lokal.	Loss dan accuracy per node.
7. Penyimpanan	Node-1/2/3	Model disimpan sebagai file .h5 di workspace.	model_nodeX_final.h5.

Rumus konseptual FedAvg:


$w_{\text{global}} = \sum((n_k / n_{\text{total}}) * w_k)$ untuk semua client k

Karena setiap node pada eksperimen ini memiliki 2.000 record, kontribusi tiap node terhadap metrik global relatif seimbang. Akurasi global round ketiga sebesar 90,05% juga konsisten dengan rata-rata akurasi lokal Node-1, Node-2, dan Node-3.


7. Matriks Evaluasi dan Hasil Eksperimen

Bagian ini menyajikan matriks evaluasi berdasarkan log training terakhir yang diberikan. Evaluasi dibagi menjadi metrik global per round dan metrik lokal per node.

Metrik		Nilai	
Jumlah round		3 round	
Durasi total		114,30 detik	
Jumlah node/client		3 client	
Jumlah data per node		2.000 record	
Total data training		6.000 record	
Jumlah kelas		3 kelas: BENIGN, DDoS, PortScan	
Round	Distributed Loss	Distributed Accuracy	Keterangan
1	0.8234	79.97%	Baseline awal
2	0.4647	82.93%	Membaik
3	0.3982	90.05%	Membaik




Gambar 2. Tren penurunan global loss selama 3 round federated learning.



Gambar 3. Tren peningkatan global accuracy selama 3 round federated learning.

Indikator		Perhitungan			Interpretasi	
Penurunan loss round 1 ke round 3		0.8234 ke 0.3982 = turun 51.63%			Model global semakin baik dalam meminimalkan kesalahan klasifikasi.	
Kenaikan accuracy round 1 ke round 3		79.97% ke 90.05% = naik 10.08 poin persentase			Kemampuan klasifikasi global meningkat setelah agregasi antar-node.	
Durasi training		114,30 detik untuk 3 round			Cukup ringan untuk eksperimen lokal berbasis Docker CPU.	
Node	Dataset	Dominasi Data	Record	Loss Lokal	Accuracy Lokal	Model
Node-1	dataset_node1_ddos.csv	DDoS Benign +	2000	1.1207	71.85%	/workspace/model_node1_final.h5
Node-2	dataset_node2_portscan.csv	PortScan Benign +	2000	0.0627	98.50%	/workspace/model_node2_final.h5
Node-3	dataset_node3_benign.csv	Benign	2000	0.0113	99.80%	/workspace/model_node3_final.h5



Gambar 4. Perbandingan accuracy lokal antar-node pada evaluasi akhir.

7.1 Penjelasan Matriks/Metrik Evaluasi

Metrik	Formula/Konsep	Makna dalam IDS
Loss	Categorical crossentropy pada klasifikasi multi-kelas.	Semakin kecil loss, semakin rendah kesalahan probabilitas prediksi model.
Accuracy	Jumlah prediksi benar dibagi total sampel.	Mengukur persentase trafik yang diklasifikasikan benar.
Distributed loss	Loss agregat hasil evaluasi seluruh client.	Menggambarkan performa model global pada data terdistribusi.
Distributed accuracy	Accuracy agregat berbobot jumlah sampel client.	Menggambarkan performa global federated learning.
Local node accuracy	Accuracy model global ketika dievaluasi pada data lokal tiap node.	Menunjukkan apakah model global cocok terhadap distribusi data node tertentu.

Confusion matrix, precision, recall, dan F1-score belum dapat dihitung dari log yang tersedia karena log hanya memuat loss dan accuracy, bukan daftar y_true dan y_pred per sampel. Untuk laporan lanjutan, script evaluasi perlu ditambah agar menyimpan prediksi per baris ke CSV sehingga confusion matrix BENIGN vs DDoS vs PortScan dapat dihitung.

8. Analisis Hasil

Secara global, hasil menunjukkan tren positif. Loss turun konsisten dari round 1 hingga round 3, sementara accuracy naik hingga mencapai 90,05%. Ini berarti proses agregasi FedAvg berhasil membentuk model global yang semakin representatif terhadap gabungan data antar-node.

Akan tetapi, performa lokal Node-1 jauh lebih rendah dibanding Node-2 dan Node-3. Node-1 memperoleh accuracy 71,85% dengan loss 1,1207. Node-2 memperoleh accuracy 98,50% dengan loss 0,0627, sedangkan Node-3 memperoleh accuracy 99,80% dengan loss 0,0113. Selisih performa ini menunjukkan bahwa data Node-1 kemungkinan lebih sulit atau memiliki distribusi yang berbeda dari node lain.

Temuan	Bukti dari Hasil	Makna Teknis
Model global mengalami konvergensi awal	Loss turun dari 0,8234 ke 0,3982.	Agregasi antar-client memperbaiki parameter global.
Accuracy global meningkat	Accuracy naik dari 79,97% ke 90,05%.	Model semakin mampu mengklasifikasi trafik setelah beberapa round.
Distribusi data tidak seragam	Node-1 71,85%, Node-2 98,50%, Node-3 99,80%.	Terjadi indikasi non-IID; model global lebih cocok pada node tertentu.
Node-3 sangat tinggi	Node-3 accuracy 99,80%.	Kemungkinan karena data Node-3 didominasi/berisi BENIGN sehingga pola lebih homogen.
Node-1 menjadi titik lemah	Loss Node-1 paling tinggi, yaitu 1,1207.	Perlu balancing, evaluasi fitur, atau penambahan round untuk memperbaiki generalisasi.

8.1 Interpretasi Non-IID

Federated learning pada data jaringan hampir selalu menghadapi perbedaan distribusi antar-node. Pada eksperimen ini, Node-1 berisi kombinasi DDoS dan BENIGN, Node-2 berisi PortScan dan BENIGN, sedangkan Node-3 berisi BENIGN. Perbedaan ini membuat setiap client melihat pola trafik yang berbeda. Ketika model global dikirim kembali ke client, model tersebut belum tentu optimal untuk semua node.

Dalam konteks IDS, hal ini bukan kelemahan kecil. Jika Node-1 mewakili lokasi yang banyak menerima serangan DDoS, akurasi Node-1 yang lebih rendah berarti sistem masih berisiko gagal mengenali pola serangan tertentu pada node tersebut. Karena itu, angka global 90,05% harus dibaca bersama metrik lokal, bukan berdiri sendiri.

9. Deteksi CSV Baru Tanpa Label

Pada tahap deployment, CSV uji tidak wajib memiliki kolom Label. Label hanya wajib pada tahap training supervised. Setelah model .h5 tersedia, file CSV baru dapat diproses oleh script deteksi untuk menghasilkan label prediksi dan status anomali.

Kolom Output Deteksi	Makna
Predicted_Label	Hasil prediksi model: BENIGN, DDOS, atau PORTSCAN.
Confidence	Probabilitas tertinggi dari output softmax; semakin tinggi semakin yakin.
Is_Anomaly	True jika Predicted_Label bukan BENIGN; False jika BENIGN.

Catatan: sistem ini bukan anomaly detection unsupervised murni. Sistem ini adalah supervised classification IDS. Artinya, model belajar dari label BENIGN, DDoS, dan PortScan. Oleh karena itu, jika data training benar-benar tidak memiliki label, pendekatan klasifikasi tiga kelas tidak sah secara metodologis. Untuk data training tanpa label, pendekatan yang lebih tepat adalah autoencoder atau metode unsupervised lain yang hanya menghasilkan normal/anomali, bukan jenis serangan spesifik.

10. Keterbatasan dan Rekomendasi Pengembangan

Keterbatasan	Dampak	Rekomendasi
Jumlah round hanya 3	Model belum tentu mencapai konvergensi optimal.	Uji 10, 20, dan 50 round untuk melihat stabilitas loss dan accuracy.
Metrik terbatas pada loss dan accuracy	Belum terlihat performa per kelas, terutama kelas minoritas.	Tambahkan confusion matrix, precision, recall, F1-score, dan ROC-AUC.
Distribusi data non-IID	Akurasi Node-1 lebih rendah dari node lain.	Gunakan class weighting, oversampling, atau stratifikasi dataset.
Model sederhana	Kapasitas model mungkin belum optimal untuk trafik kompleks.	Bandingkan Dense Neural Network dengan Random Forest, XGBoost, LSTM, atau 1D-CNN.
Penyimpanan model HDF5	Format .h5 masih bisa dipakai tetapi muncul warning legacy dari Keras.	Gunakan format .keras untuk eksperimen berikutnya.
Normalisasi lokal per node	Skala fitur dapat berbeda antar-node.	Pertimbangkan scaler global yang aman atau standardisasi konsisten untuk deployment.
Belum ada deteksi real-time	Sistem masih berbasis CSV batch.	Integrasikan dengan packet capture/log collector untuk pipeline near-real-time.

11. Kesimpulan

Implementasi federated learning IDS menggunakan Flower, TensorFlow/Keras, dan Docker Compose berhasil dijalankan dengan 1 server dan 3 client. Proses training selesai dalam 3 round selama 114,30 detik. Hasil global menunjukkan performa yang meningkat, ditandai dengan penurunan distributed loss dari 0,8234 menjadi 0,3982 dan kenaikan distributed accuracy dari 79,97% menjadi 90,05%.

Dari sisi lokal, Node-2 dan Node-3 menunjukkan performa sangat tinggi, sedangkan Node-1 masih menjadi titik lemah dengan accuracy 71,85%. Hal ini menunjukkan bahwa evaluasi federated learning tidak cukup hanya melihat angka global. Analisis per-node wajib dilakukan karena setiap node dapat memiliki distribusi trafik dan tingkat kesulitan klasifikasi yang berbeda.

Secara keseluruhan, sistem sudah layak dijadikan baseline IDS berbasis federated learning untuk klasifikasi BENIGN, DDoS, dan PortScan. Untuk menghasilkan laporan penelitian atau tugas akhir yang lebih kuat, eksperimen perlu ditambah dengan confusion matrix, precision, recall, F1-score, variasi jumlah round, dan validasi pada CSV uji tanpa label.

Lampiran A. Daftar Fitur Dataset

Tabel berikut memuat daftar fitur input yang digunakan oleh model. Kolom Label tidak dimasukkan sebagai fitur karena digunakan sebagai target klasifikasi pada tahap training.

No 1	Nama Fitur 1	No 2	Nama Fitur 2	No 3	Nama Fitur 3
1	Protocol	27	Bwd IAT Mean	53	Avg Packet Size
2	Flow Duration	28	Bwd IAT Std	54	Avg Fwd Segment Size
3	Total Fwd Packets	29	Bwd IAT Max	55	Avg Bwd Segment Size
4	Total Backward Packets	30	Bwd IAT Min	56	Fwd Avg Bytes/Bulk
5	Fwd Packets Length Total	31	Fwd PSH Flags	57	Fwd Avg Packets/Bulk
6	Bwd Packets Length Total	32	Bwd PSH Flags	58	Fwd Avg Bulk Rate
7	Fwd Packet Length Max	33	Fwd URG Flags	59	Bwd Avg Bytes/Bulk
8	Fwd Packet Length Min	34	Bwd URG Flags	60	Bwd Avg Packets/Bulk
9	Fwd Packet Length Mean	35	Fwd Header Length	61	Bwd Avg Bulk Rate
10	Fwd Packet Length Std	36	Bwd Header Length	62	Subflow Fwd Packets
11	Bwd Packet Length Max	37	Fwd Packets/s	63	Subflow Fwd Bytes
12	Bwd Packet Length Min	38	Bwd Packets/s	64	Subflow Bwd Packets
13	Bwd Packet Length Mean	39	Packet Length Min	65	Subflow Bwd Bytes
14	Bwd Packet Length Std	40	Packet Length Max	66	Init Fwd Win Bytes
15	Flow Bytes/s	41	Packet Length Mean	67	Init Bwd Win Bytes
16	Flow Packets/s	42	Packet Length Std	68	Fwd Act Data Packets
17	Flow IAT Mean	43	Packet Length Variance	69	Fwd Seg Size Min
18	Flow IAT Std	44	FIN Flag Count	70	Active Mean
19	Flow IAT Max	45	SYN Flag Count	71	Active Std
20	Flow IAT Min	46	RST Flag Count	72	Active Max
21	Fwd IAT Total	47	PSH Flag Count	73	Active Min
22	Fwd IAT Mean	48	ACK Flag Count	74	Idle Mean
23	Fwd IAT Std	49	URG Flag Count	75	Idle Std
24	Fwd IAT Max	50	CWE Flag Count	76	Idle Max
25	Fwd IAT Min	51	ECE Flag Count	77	Idle Min
26	Bwd IAT Total	52	Down/Up Ratio		

Lampiran B. Command Operasional Docker

Berikut command yang dapat digunakan untuk menjalankan sistem dan memisahkan tampilan log server serta node.

```
docker compose build
docker compose down
docker compose up -d
```

Menampilkan log per service:

```
docker compose logs -f server
docker compose logs -f node1
docker compose logs -f node2
docker compose logs -f node3
```

Menjalankan service satu per satu seperti workflow WSL:

```
docker compose up server
docker compose up node1
docker compose up node2
docker compose up node3
```

Mengecek container yang aktif:

```
docker compose ps
```

Mengecek koneksi node ke server pada port Flower 8081:

```
docker exec Node-1 python -c "import socket; s=socket.socket(); s.settimeout(3);
s.connect(('server',8081)); print('Node-1 berhasil connect ke server:8081'); s.close()"
```

Lampiran C. Ringkasan Log Eksperimen yang Digunakan

Sumber Log	Nilai Utama
Server-FL	Run finished 3 round(s) in 114.30s.
Server-FL loss	Round 1 = 0.8233507791; round 2 = 0.4647293274; round 3 = 0.3982344481.
Server-FL accuracy	Round 1 = 0.7996666729; round 2 = 0.8293333451; round 3 = 0.9005000194.
Node-1	Loss = 1.1207; Accuracy = 0.7185; Model = /workspace/model_node1_final.h5.
Node-2	Loss = 0.0627; Accuracy = 0.9850; Model = /workspace/model_node2_final.h5.
Node-3	Loss = 0.0113; Accuracy = 0.9980; Model = /workspace/model_node3_final.h5.